



Los siguientes son los criterios de evaluación que se tendrán en cuenta durante la prueba técnica de evaluación en conocimientos en Senior Data Engineer:

Precisión: Respuestas acotadas, concretas y claras.

Fundamentación: Entendimiento de lo que se habla. Ser coherentes y consecuentes en todo el proceso de la prueba con argumentos que sustenten cada respuesta.

Calidad: Cumplir con los criterios de aceptación de cada prueba. Entregar lo que se solicita de la mejor forma posible.

Creatividad: La originalidad, formas nuevas y enfoques distintos en la presentación de lo solicitado se apreciará en la valoración final.

Oportunidad: Entregar en el tiempo convenido. Trabajar dentro de un *time-box* es muy importante cuando hablamos de principios ágiles.



Prueba Técnica: Senior Data Engineer +BI

Objetivo: Evaluar la capacidad del candidato para diseñar, implementar y optimizar un flujo de datos completo (End-to-End), demostrando criterios de arquitectura en Data Lakes, gobierno de datos, habilidades avanzadas de modelado/visualización, y aptitudes para el coliderazgo y desarrollo de talento técnico.

Fase 1: Arquitectura y Estrategia de Data Lake (Teórica / Caso de Estudio)

Esta fase evalúa el criterio senior, diseño de sistemas y conocimiento de capas.

Contexto del caso:

Nuestra organización está migrando su ecosistema de datos a un Data Lake. Actualmente, recibimos datos de tres fuentes principales:

1. Una base de datos transaccional SQL (ventas en tiempo real).
2. Archivos JSON semiestructurados desde una API de terceros (comportamiento de usuarios en la web).
3. Archivos CSV estáticos (metadatos de productos y catálogos).

Preguntas a resolver:

1. **Capas del Data Lake:** Explica detalladamente cómo organizarías estas fuentes dentro de las capas del Data Lake (**Bronze/Raw, Silver/Cleaned, Gold/Curated**). ¿Qué transformaciones y controles de calidad ocurren en cada paso?
2. **Estrategia de Ingesta y Particionamiento:** ¿Qué estrategia utilizarías para la ingesta de la base de datos transaccional sin afectar el rendimiento del sistema en producción? ¿Bajo qué criterios particionarías los datos en el Data Lake para optimizar las consultas analíticas?
3. **Evolución del Esquema:** Si la API de terceros cambia drásticamente la estructura del JSON (agrega o elimina campos), ¿cómo asegurarías que el pipeline no falle y cómo manejarías la evolución del esquema?

Fase 2: Implementación del Pipeline ETL (Práctica)

Esta fase evalúa la calidad de código, manejo de herramientas de Big Data/procesamiento y lógica de transformación.

Nota para el candidato: Puedes resolver este ejercicio utilizando Python (Pandas/Polars) o PySpark/SQL. Se valorará el uso de buenas prácticas (modularización, manejo de excepciones, logs).



El Reto:

Se te proporcionan dos datasets simulados:

- `usuarios_raw.json`: Datos demográficos con duplicados, valores nulos en campos críticos y formatos de fecha inconsistentes.
- `transacciones_raw.csv`: Registros de compras con montos en texto (ej. "\$1,200.50") y fechas en formato UNIX timestamp.

Tareas a realizar:

1. **Extracción y Limpieza (Hacia Capa Silver):**
 - Remueve duplicados basados en reglas de negocio (ej. quedarte con el registro más reciente del usuario).
 - Estandariza los formatos de fecha a `YYYY-MM-DD`.
 - Limpia y convierte a volar numérico las columnas numéricas.
 - Maneja los valores nulos (explica tu criterio: ¿imputación o eliminación?).
2. **Transformación y Modelado (Hacia Capa Gold):**
 - Realiza un *join* eficiente entre ambos datasets.
 - Crea una tabla agregada (Modelo Dimensional o Tablón Analítico) que calcule por usuario: **Total gastado, número de transacciones y ticket promedio**.
3. **Carga:**
 - Exporta el resultado final en un formato optimizado para analítica (idealmente **Parquet** o **Delta**) aplicando un particionamiento lógico (por ejemplo, por Año/Mes de la transacción).

Fase 3: Visualización e Insights - Tableau (Práctica / Análisis)

Esta fase evalúa el perfil híbrido hacia analista de datos, asegurando que el candidato entiende el valor final del dato.

El Reto:

Utilizando el dataset resultante de la Capa Gold (Fase 2), debes diseñar una propuesta de Dashboard en Tableau para el equipo de negocio (C-Level).

Requerimientos:

1. **Diseño del Dashboard:** Describe brevemente (o dibuja un mock up / esquema) qué componentes incluirías para responder a la pregunta: *"¿Quiénes son nuestros clientes más valiosos y cómo evolucionan sus compras mes a mes?"*
2. **Conceptos Técnicos de Tableau (Preguntas de control):**
 - Explica la diferencia entre usar una **Conexión en Vivo (Live)** y un **Extracto (Extract)** en Tableau para este volumen de datos alojado en el Data Lake. ¿Cuál elegirías



y por qué?

- ¿En qué escenario utilizarías una expresión **LOD (Level of Detail)** como `FIXED` en lugar de una agregación normal en una visualización?
- ¿Cómo optimizarías un libro de trabajo (Workbook) de Tableau que está tardando demasiado en cargar?

👉 Fase 4: Liderazgo Técnico y Mentoring (Caso de Estudio)

Esta fase evalúa las habilidades blandas, la pedagogía y la capacidad del perfil Senior para elevar el nivel técnico del equipo.

Contexto del caso:

Un ingeniero de datos Junior de tu equipo fue asignado para resolver la limpieza del archivo `usuarios_raw.json` (Fase 2). En su propuesta de código, entregó un script que utiliza bucles anidados (`for` loops) para iterar fila por fila de todo el dataset, usando funciones nativas de manipulación de cadenas de Python para corregir las fechas, y guardando todo en listas auxiliares para eliminar duplicados.

El script funciona correctamente en su entorno local con 100 registros, pero al integrarse al pipeline de producción con millones de registros, satura la memoria RAM del servidor y detiene el proceso.

Preguntas a resolver:

1. **Code Review y Feedback:** ¿Cómo abordarías la sesión de revisión de código con este ingeniero Junior? Describe tu enfoque comunicativo para explicarle la diferencia entre un procesamiento secuencial y uno vectorizado/declarativo sin desmotivarlo.
 2. **Estrategia de Mentoría:** Propón un plan de acción a corto plazo (ej. dinámicas de *Pair Programming*, lecturas o mini-proyectos) para ayudar a este ingeniero Junior a migrar su lógica hacia buenas prácticas de manipulación de datos a gran escala empleando herramientas como DataFrames (Pandas, PySpark o SQL).
- 1.

Criterios Técnicos de Evaluación

Foco: Rendimiento, Calidad del Pipeline, Seguridad y Liderazgo Técnico.

- **Optimización del Pipeline:** El pipeline de datos desarrollado debe demostrar una reducción de tiempos de procesamiento y optimizar la lectura en memoria mediante buenas prácticas de desarrollo.
- **Estrategia de Almacenamiento:** El candidato debe justificar técnicamente por qué eligió ciertos tipos de datos, formatos de archivo (Parquet vs Delta) y esquemas de particionamiento basándose en el tipo de cargas de negocio.



- **Seguridad de Menor Privilegio:** Los esquemas de acceso a datos para consumo final deben otorgar permisos estrictamente necesarios, evitando el uso de superusuarios o accesos irrestrictos a las capas crudas (Raw).
- **Capacidad de Mentoring y Soft Skills:** Se evaluará críticamente la habilidad del candidato para desglosar conceptos complejos de Big Data/Data Lakes a un lenguaje accesible para un perfil Junior. Se buscará empatía, pedagogía y la implementación de dinámicas de mejora continua (ej. Pair Programming, guías de estilo).

Instrucciones de Entrega

- **Código:** Repositorio de GitHub/GitLab con la solución de la Parte 2 y la Parte 3, incluyendo un `README.md` claro y un archivo `requirements.txt` o `poetry.lock`.
- **Video:** Un video explicativo donde se vea la cara del participante, con una duración máxima de 5 minutos, explicando las decisiones de diseño arquitectónico (Parte 1), la optimización del pipeline (Parte 2), la solución de visualización (Parte 3) y su enfoque pedagógico para el caso del ingeniero Junior (Parte 3).
- **Tiempo estimado para su realización:** 48 a 72 horas.